

BIO4901 Lab 8: ESM-2 蛋白质亚细胞定位

参数适配、计算成本与同源性敏感评估

Yukai Wang

2026-09-17

目录

1	背景介绍	1
2	实验数据与方法	1
2.1	数据来源与标签清洗	1
2.2	Leakage-aware validation	2
2.3	表征与适配策略	2
2.4	LoRA 算法	2
2.5	设备、成本与可复现性	3
2.6	指标与统计推断	3
3	实验流程	3
4	实验结果与分析	4
4.1	配对 bootstrap 区间	7
4.2	生物学解释框架	7
5	讨论与总结	7
5.1	局限性	7
5.2	伦理与数据声明	8
5.3	待全量运行后回答	8
6	参考文献	8

1 背景介绍

蛋白质序列包含与折叠、运输及定位相关的信息。ESM-2 通过掩码语言建模学习序列表征 [2]，但预训练表征能否在有限标注条件下支持定位分类，以及适配带来的提升是否值得额外计算成本，需要实证比较。本实验采用固定版本的 `facebook/esm2_t30_150M_UR50D`，比较 Frozen embedding + kNN、Linear probing、LoRA 和全参数微调。

研究问题包括：不同适配策略在官方同源簇划分下的预测表现如何；参数量、训练时间与显存如何变化；高 benchmark 分数是否对应可靠校准、长度泛化及合理的定位信号使用。

本报告当前为本地冒烟验证稿；结果不能用于回答策略优劣。所有正式结论待 GPU 全量运行后补充。

2 实验数据与方法

2.1 数据来源与标签清洗

使用 DeepLoc-1.0 官方 FASTA [1]。原文件有 14,004 条记录；146 条 Cytoplasm-Nucleus 双定位记录不适用于本实验十类单标签设定，明确排除，保留 13,858 条。header 中 `-S/-M/-U` 表示 soluble、membrane、unknown，独立保存为生物学分组变量，不参与定位标签预测。原始 Plastid 映射为课程所用 Chloroplast，但该名称映射不代表原注释都精确限定于叶绿体。




图 1: 完整数据集的类别分布与长度分布。此 QC 使用全部保留记录, 而非 subset。

2.2 Leakage-aware validation

只通过 header 末尾独立的 test token 识别官方测试记录, 不随机重分 train/test。原论文第 2.3.1 节说明: 使用 PSI-CD-HIT, 以 30% identity 或 10^{-6} E-value 条件聚类, 并要求覆盖较短序列的 80%; 同源簇整体分入五折, 其中一折留出测试 [1]。本项目继承这一划分, 不声称自行重现该聚类过程。

SHA-256 完整序列摘要检查显示跨集合重复数为零; 训练内部有 49 条重复序列, 测试内部有 5 条。该审计可以发现完全相同序列泄漏, 不能证明所有跨集合序列都低于某一同源性阈值。ESM 预训练语料可能包含相关蛋白, 不能据此排除预训练重叠。测试内部相关性也限制序列级 bootstrap 的解释。

FASTA 不提供原训练集的四折簇 ID。本实现固定学习率和训练轮数、使用最后 checkpoint, 不使用测试分数进行 early stopping、超参数选择或校准参数拟合。若后续需要调参, 须在官方训练集内部另外获得/构建同源簇验证折, 不能反复查看本测试集选模型。

2.3 表征与适配策略

使用非 padding、非 BOS/EOS token 的平均隐状态, 维度为 640。长序列保留前半段和后半段, 删除中部, 以尽量保留 N/C 端运输信号; 本地上限为 128 个残基, 全量默认 512, 可通过 CLI 修改到 1022。截断比例保存在 QC summary; 输入截断本身是实验局限。

策略	可训练部分	分类方式
Frozen	无梯度训练参数	固定表征, 余弦距离 5-NN, 距离加权投票
Linear	640×10 权重与 10 维偏置	固定表征上的 softmax 线性层
LoRA	query/value 低秩矩阵及分类头	rank 8, alpha 16, dropout 0.05
Full FT	编码器和分类头	更新用于分类的全部参数; 未使用 contact head 冻结

Frozen 分类器仍需存储参考样本, 零可训练参数不等于零存储或推断成本。Linear 的成本计入共享 embedding 提取; 不同方法使用相同训练/测试 ID 和预处理。若显存降级修改最大长度或冻结层数, 元数据明确记录, 不能继续作为严格同预算 full-FT 比较。

2.4 LoRA 算法

对目标线性映射 $W_0 \in \mathbb{R}^{d_{out} \times d_{in}}$, 令 $W = W_0 + (\alpha/r)BA$, 其中 $A \in \mathbb{R}^{r \times d_{in}}$ 、 $B \in \mathbb{R}^{d_{out} \times r}$; 固定 W_0 , 仅更新 A, B 和分类头 [3]。

Algorithm 1: LoRA adaptation for protein localization

Input: Official training sequences D , pretrained encoder W_0 , rank $r = 8$

Output: Adapter matrices A, B and classification head C

Freeze W_0 ; initialize A randomly and $B = 0$; initialize C ;

for each fixed training epoch do

for each accumulation group of mini-batches do

 Zero optimizer gradients;

for each mini-batch (x, y) do

 Preserve sequence termini; tokenize x ;

 Compute encoder states with $W_0 + (\alpha/r)BA$;

 Mean-pool valid residue states and compute logits using C ;

 Accumulate sample-weighted cross-entropy gradients;

 Clip gradients; update A, B, C only;

 Save trainable tensors, optimizer state and random-number states;

Evaluate the final checkpoint on the untouched official test set;

2.5 设备、成本与可复现性

设备优先级为 CUDA、MPS、CPU。本地使用 ARM64 Mac 的 MPS，24 GiB 统一内存。混合精度先检测 bf16 可用性，否则回退 fp32。CUDA Full FT 默认开启 bf16、gradient checkpointing、8-bit AdamW、batch 4、有效 batch 16。显存预检不仅运行微型输入，还运行配置的最大形状并执行 optimizer step，以包括惰性分配的优化器状态；探测更新随后丢弃。OOM 降级依次减 batch、减长度、冻结前层，并记录改变后的方法名。

日志每 30 秒心跳输出运行时长、ETA、step/loss/accuracy 和内存；训练以 epoch 为单位保存可恢复状态。本地没有 CUDA，8-bit optimizer 与 CUDA peak memory 尚未实机验证。MPS 当前分配内存不是 CUDA peak 显存，也不等于设备总内存峰值。

2.6 指标与统计推断

报告 accuracy、固定十类 macro F1、10 个等宽区间 top-label ECE、NLL 与多分类 Brier score。可靠性图仅绘制非空区间。使用 1,000 次按真实类别分层的配对 bootstrap，四种方法共享相同的重采样样本，输出单方法与两两差值的 95% percentile CI。区间条件于测试样本和固定类别数量，未包含训练 seed 方差；不是同源簇级 CI。测试集未用于 temperature scaling。

3 实验流程




图 2: 数据至评估与统计的 DAG；四个适配分支共用官方测试样本。

Snakemake 通过 subset=True/False 切换本地冒烟和服务器全量配置。原始 FASTA、embedding 与大权重均不提交，代码、QC、CSV、矢量图与 checkpoint 配置提交。下载文件 SHA-256、模型不可变 revision、软件版本、设备和运行参数记录在对应 JSON。

4 实验结果与分析

[PLACEHOLDER - 待服务器全量运行后替换]

全量数据 QC：原始 14,004 条；十类任务保留 13,858 条；排除双定位 146 条。训练 11,085 条，测试 2,773 条。跨集合完全重复序列数为 0。

方法	Accuracy	Macro F1	ECE	可训练参数	时间/s
frozen	0.400	0.258	0.218	0	4.5
linear	0.250	0.040	0.054	6,410	4.8
lora	0.275	0.102	0.144	620,810	20.4
full	0.225	0.042	0.095	148,391,050	7.7

每种方法测试样本数：40。时间包含该阶段模型准备、训练与推断；Linear 计入共享 embedding 提取成本。网络缓存、硬件与测试规模影响时间，不用于跨设备成本推断。

本地 MPS 内存不是 CUDA 显存；CUDA peak 字段留空。Full FT 冒烟仅执行一个 optimizer step，分数不能用于比较适配策略。






图 3：可训练参数量。冒烟占位结果。



SMOKE TEST / PLACEHOLDER - not a performance ranking

图 4: 性能与成本。冒烟占位结果。



SMOKE TEST / PLACEHOLDER - not a performance ranking

图 5: 校准曲线。冒烟占位结果。




图 6: 混淆矩阵。冒烟占位结果。




图 7: Embedding PCA。冒烟占位结果。




图 8: 训练曲线。冒烟占位结果。

4.1 配对 bootstrap 区间

差值方向	指标	估计差	95% CI
frozen - linear	accuracy	0.150	[0.025, 0.250]
frozen - linear	macro_f1	0.218	[0.120, 0.298]
frozen - lora	accuracy	0.125	[-0.026, 0.275]
frozen - lora	macro_f1	0.156	[0.041, 0.250]
frozen - full	accuracy	0.175	[0.049, 0.300]
frozen - full	macro_f1	0.216	[0.118, 0.295]
linear - lora	accuracy	-0.025	[-0.125, 0.075]
linear - lora	macro_f1	-0.062	[-0.112, -0.011]
linear - full	accuracy	0.025	[0.000, 0.075]
linear - full	macro_f1	-0.002	[-0.009, 0.007]
lora - full	accuracy	0.050	[-0.075, 0.175]
lora - full	macro_f1	0.060	[0.006, 0.112]

序列级分层配对 bootstrap 固定观测类别比例。样本相关性与训练随机性未包含在区间内；没有同源簇 ID 时，不能把这些区间解释为家族独立泛化的完整不确定性。

4.2 生物学解释框架

校准度与分类正确率应同时解读：弱分类器也可能有较小 ECE，不能仅据 ECE 判断可用性。核定位与胞质定位的混淆可能反映定位信号重叠，但本实验不能从混淆矩阵直接证明分子机制。PCA 仅展示表示结构，不是聚类质量或定位因果机制的证据。

robustness_by_group.csv 提供长度组、膜/可溶组与每类表现，并加入截断后两端各最多 10 个残基替换为 X 的诊断。端点扰动若使分数下降，仅提示模型对相关输入敏感；X 并非真实生物突变，需结合真实信号肽、定位序列注释进行后续验证。小样本分组结果尤其不稳定。

5 讨论与总结

5.1 局限性

当前仅完成本地 pipeline 检查；Full FT 只更新一个 batch，其他方法只有 200 条训练样本、两轮训练，不能进行科学排名。正式运行须保留原测试集、补齐 GPU 实测峰值和训练成本，并尽可能增加训练随机种子。

数据类别不平衡、少数类数量有限；序列截断可能删除功能信号。单标签任务排除了双定位蛋白，不覆盖复杂细胞状态与动态运输。继承的同源簇划分降低监督训练泄漏风险，但不排除预训练重叠；序列级重采样亦可能低估同源相关性。单一物种集合与时期的注释不能代表所有真实应用分布。

自动冻结层会改变问题设定，必须作为部分层微调单独报告。CPU/MPS 的时间和内存不能外推 RTX 3090 Ti；预检并不保证所有生产负载都不会 OOM。

5.2 伦理与数据声明

数据来自公开的研究资源，依来源规范引用；不上传原始序列到 git。工作用于教学研究，不用于临床或病原体工程决策。本地冒烟结果均明示为占位，不伪造全量或 CUDA 验证结果。代码与报告草稿由 AI 辅助实现，作者应审核实验配置、数据解释和最终提交内容。

5.3 待全量运行后回答

正式结论应围绕宏平均性能提升是否稳定、增益是否足以解释额外计算成本、对少数类和长序列是否泛化，以及校准与端点扰动是否一致，而非只比较一项总体 accuracy。

6 参考文献

1. Almagro Armenteros JJ, Sønderby CK, Sønderby SK, Nielsen H, Winther O. DeepLoc: prediction of protein sub-cellular localization using deep learning. *Bioinformatics*. 2017;33(21):3387–3395. doi:10.1093/bioinformatics/btx431.
2. Lin Z, Akin H, Rao R, et al. Evolutionary-scale prediction of atomic-level protein structure with a language model. *Science*. 2023;379:1123–1130. doi:10.1126/science.ade2574.
3. Hu EJ, Shen Y, Wallis P, et al. LoRA: Low-Rank Adaptation of Large Language Models. *ICLR*. 2022. arXiv:2106.09685.
4. DeepLoc-1.0 官方数据说明.
5. ESM-2 150M 模型与权重.