

用 ESM-2 预测蛋白质定位

BIO4901 · Lab 8 · 四种适配方法的比较

Yukai Wang

1 背景与生物学问题

蛋白质需要到达正确的位置才能发挥作用。序列中的某些片段相当于“地址”，可以帮助预测位置。

本实验的问题是：固定使用、少量调整或充分调整同一个预训练模型，预测效果与计算成本有何不同？模型分数的提高，是否伴随对定位相关信息的依赖？

我们用预训练的 ESM-2 150M，把每条序列分为十种位置之一 [1,2]。

2 实验数据

数据来自 DeepLoc-1.0 官方 FASTA [1]。14,004 条原记录中，排除 146 条“双定位”记录，得到 **11,085** 条训练序列、**2,773** 条测试序列。十类标签见图 1；原始标签 Plastid 按课程用语记为 Chloroplast，其实际范围比叶绿体更宽。




图 1：数据概况。左：官方训练与测试集的分类数量；右：完整序列的长度分布。

划分方式。完全沿用 header 中的 test 标记，不重新随机划分。原论文先按序列同源性分组，再留出测试组。我们另外检查了序列与编号：跨集合的完全重复均为 0。这能排查重复，但不等于重新验证所有同源关系，也不能排除预训练语料重叠。

数据处理。所有方法最多读取 512 个残基；更长的序列保留首尾、删除中间。完整数据约 38% 会截断。类别数量最多与最少相差约 26 倍，因此同时报告总体正确率和各类平均 F1，避免只看大类别。

3 算法与实验流程

3.1 四种方法

先用 ESM-2 把每个残基转成向量，再对有效残基取平均，得到一个 640 维的蛋白质表征。三种需要训练的方法都输出十类概率，以交叉熵衡量预测与标签的差别。

方法	我们实际做了什么
Frozen + kNN	固定 ESM-2，找训练集中最相近的 5 条序列，按距离加权投票。
Linear probing	固定 ESM-2，只训练一个 640→10 的分类层。
LoRA	在注意力的 query/value 中加入小矩阵，只训练它们和分类层。
Full FT	更新 ESM-2 编码器与分类层；不训练无关的 contact head。

LoRA 用两个小矩阵表示权重变化： $W = W_0 + (\alpha/r)BA$ 。本次 $r = 8$ 、 $\alpha = 16$ ；原权重 W_0 保持不变 [3]。

Algorithm 1: 四种方法共用的流程

Input: 官方训练集、官方测试集、预训练 ESM-2
对序列保留首尾并分词，屏蔽补齐位置；
if *Frozen* **then**
 提取固定表征，保存训练集的 5-NN 参考库；
else
 按方法设置可更新参数；
 for 10 轮训练 **do**
 预测训练标签，计算交叉熵，更新参数并保存 checkpoint；
使用最终模型预测官方测试集；不根据测试分数选择模型；
统一计算性能、成本、校准与重采样区间；

共同设置	数值	学习率	数值
模型 / 随机种子	ESM-2 150M / 42	Linear	0.001
训练轮数 / 最长输入	10 / 512 残基	LoRA	0.0001
LoRA、Full 实际 / 有效 batch	4 / 16	Full FT	0.00001

LoRA、Full FT 使用 bf16、梯度检查点和 8-bit AdamW；Linear 使用普通 AdamW。服务器为 RTX 3080 Ti 12 GiB，此次没有触发显存降级。




图 2: 可复现流程：同一数据、四种适配、统一评估。

4 实验结果与分析

4.1 哪种方法更准确，代价多大？

方法	Accuracy	Macro F1	更新参数	时间/min	显存/GiB
Frozen + kNN	69.3%	0.574	0	6.9	0.77
Linear	75.3%	0.590	6,410	6.5	0.77
LoRA	77.1%	0.614	620,810	107.4	1.07
Full FT	79.3%	0.685	148,391,050	107.8	2.12

Accuracy 是预测正确的比例；Macro F1 综合误判与漏判情况，并对十类取平均，每类权重相同。时间包含模型准备、训练和推断，Linear 计入表征提取；显存为 PyTorch 峰值分配量。

Full FT 的 Macro F1 最高，为 0.685；Linear 是低成本基线。 Full FT 的准确率为 79.3%，Linear 为 75.3%。参数调整带来了改善，但这只是固定设置、一次训练的比较，并非各方法的最优成绩。




图 3: 性能与成本。纵轴为 Macro F1；左图比较更新参数量，右图比较总耗时。虚线连接在这两个指标下没有被其他方案同时超过的点。

LoRA 的更新参数只有 Full FT 的 0.42%，显存约一半，但耗时同为约 107 分钟。因为它仍需通过编码器计算梯度。Linear 连同表征提取仅需 6.5 分钟。




图 4: 方法间差异的 95% 区间。横轴为“前一种减后一种”的 Macro F1；跨过零表示差异方向尚不稳定。

Full FT 比 LoRA 的 Macro F1 高 0.071，95% 区间为 [0.045, 0.097]，未跨零。Linear 与 LoRA 的 Macro F1 差异区间跨零，不能据此认定两者有稳定差距。

区间来自 1,000 次配对重采样，四种方法共享抽样 ID 和类别比例；不包含训练种子变化，未按家族重采样或校正多重比较。

4.2 高分是否有生物学上的解释？




图 5: 各类 F1。括号为测试样本数；数字越大越好。

Full FT 的提高并不均匀：叶绿体类别 F1 为 0.920，溶酶体/液泡和过氧化物酶体分别只有 0.318、0.449。后两类仅有 64、30 条测试序列。总体分数提高，不代表所有细胞位置都已可靠区分。

许多线粒体、叶绿体蛋白在序列开头有定位片段；许多过氧化物酶体蛋白在末端有定位信号，但均存在例外 [4]。为进一步检查，我们在全部 2,773 条测试序列上补做三个对照：分别把开头、结尾、内部的等长片段替换成 X。每次最多遮蔽 10 个残基，模型不重训。




图 6: 补充实验：三个定位类别对不同遮蔽位置的反应。纵轴为该正确识别率下降的百分点；零线以下表示反而提高。内部片段为对照。完整十类结果见 CSV。

Full FT 中，遮蔽开头后，线粒体类别正确识别率下降 15.9 个百分点，内部对照下降 0.3 个百分点；叶绿体对应为 19.7 和 2.0 个百分点。过氧化物酶体遮蔽结尾后下降 26.7 个百分点，内部对照下降 0.0 个百分点。

这种位置差异与常见定位信号的分布一致；不过，过氧化物酶体仅有 30 条样本，仍需谨慎解释。

这是查看模型行为的诊断实验，不能证明模型识别了真实定位信号：X 不是生物学删除，10 个残基未必覆盖完整信号，内部对照也未必没有功能。该分析在主实验之后补做，没有用于选模型或调参。

4.3 预测有多可信，对输入变化是否稳定？




图 7: 校准曲线。越接近虚线，模型给出的信心越接近实际正确率。

Linear 的校准误差 ECE 最低 (0.043); LoRA 与 Full FT 分别为 0.145、0.153。**Full FT 更准确，但往往过于自信。**本实验没有用测试集调整置信度。若要据此筛选可靠预测，还需要独立数据做校准。




图 8: 稳定性检查。左: 不同原始长度组的准确率; 右: 同时遮蔽两端后的准确率。

Full FT 在不超过 128 残基的组中准确率为 84.1%，在超过 512 残基的组中为 77.1%。不同组的类别组成也不同，不能把差异全部归因于长度。两端同时遮蔽后，准确率从 79.3% 降至 73.2%，说明预测对端点信息敏感。

5 讨论与总结

结论。追求本次预测效果，可选 Full FT；预算有限时，Linear 更划算。LoRA 省参数和显存，但不一定省时间。高分也不保证少数类别和置信度同样可靠。

局限。单次训练、长序列截断、单标签设定和少数类不足都会影响结论。后续应补多随机种子，并用真实定位信号注释检验遮蔽实验的解释。

5.1 课程要求核对

PPT 的 required comparison	本项目提供的证据
Frozen / Linear / PEFT / Full	四种方法、相同官方测试集、完整数据。
性能与计算成本	Accuracy、Macro F1、更新参数、显存、总耗时。
生物学合理性与分数	类别 F1；补充开头/结尾/内部等长遮蔽对照。
避免泄漏的验证	官方同源分组划分；跨集序列与编号重复检查。

5.2 如何复现

进入 project8/，按以下顺序运行。环境和模型版本已固定，原始数据与权重不提交。--forceall 用于重新计算，去掉它可复用已有结果。

```
conda env create -f environment.yml
conda activate bio4901-lab8
snakemake -s scripts/Snakemfile --cores 1 --forceall \
  --config subset=False biological=True
python codes/10_write_course_report.py --results_dir results/full_run
quarto render lab8.qmd --to pdf
```

正式结果见 results/full_run/，参数见 run.json，命令见 command_log.txt。仓库: wangyukai585/BIO4901-lab8。

个人工作与伦理。本报告独立署名 Yukai Wang，无组员分工。代码、实验执行和排版使用 AI 辅助，提交前由作者核对。数据、模型和软件均注明来源；结果仅用于课程学习，不作为诊断或治疗依据。

6 参考文献

1. Almagro Armenteros JJ, et al. DeepLoc: prediction of protein subcellular localization using deep learning. *Bioinformatics*, 2017. doi:10.1093/bioinformatics/btx431.
2. Lin Z, et al. Evolutionary-scale prediction of atomic-level protein structure with a language model. *Science*, 2023. doi:10.1126/science.ade2574.
3. Hu EJ, et al. LoRA: Low-Rank Adaptation of Large Language Models. *ICLR*, 2022. arXiv:2106.09685.
4. UniProt. Transit peptide; PEX5 (P33292) 注释。转运肽说明、PTS1 识别，访问于 2026-09-18。

补充图与算法说明




图 9: 四种方法的更新参数量。Frozen 不训练参数，但需要保存参考表征。




图 10: 训练过程。三种方法均完成 10 轮；曲线不包含测试集调参。

算法代价与假设。 kNN 假设相近表征对应相近标签；每次精确查询约需 $O(Nd + N \log N)$, N 为参考数、 d 为维度。Linear 假设线性可分。注意力代价随序列长度近似平方增长；LoRA 把单层更新从 $O(d^2)$ 降至 $O(dr)$, 但仍需反向传播。

补充推断。 遮蔽实验统一使用 bf16, 并重算未遮蔽基线；与原预测的一致率为 99.3%–100%。差异涉及推断精度和 batch 大小, 原 benchmark 不变。

统计模型。 每条序列按一个十分类样本处理, 交叉熵对应真实类别的负对数概率。类别平均 F1 用于减弱大类别对评价的支配；校准误差用十个等宽置信度分箱计算。相似家族中的序列可能相关, 因此序列重采样区间可能偏窄。

补充图：错误与表征




图 11: Frozen 与 Full FT 的混淆矩阵。行是真实类别，列是预测；数字为样本数，颜色为行内比例。

Full FT 中，508 条细胞质序列有 93 条被判为细胞核，808 条细胞核序列有 77 条被判为细胞质。这是主要错误来源之一；仅凭混淆不能推断具体运输机制。




图 12: 固定表征的二维投影。PCA 只在训练集拟合，再投影测试集。

二维图只能展示高维表征的一部分。不能凭是否“成团”判断模型是否理解了生物功能，正式性能以独立测试指标为准。