

# BIO4901 Lab 8: 用 ESM-2 预测蛋白质亚细胞定位

Yukai Wang

## 1 我们想解决什么问题？

蛋白质需要到达正确的细胞位置才能发挥作用。这个实验尝试只根据氨基酸序列，判断蛋白质属于细胞核、线粒体等哪一类位置。我们使用预训练的 ESM-2 150M，比较四种使用方式：直接使用固定表征、只训练线性分类层、LoRA，以及全参数微调。

重点不只是看谁分数高，也看提升需要多少参数、时间和显存，以及模型在少数类别、不同长度序列上的表现。

## 2 数据和实验方法

DeepLoc-1.0 官方文件有 14,004 条序列。我们排除 146 条 Cytoplasm-Nucleus 双定位记录，保留 13,858 条用于十分类。原标签 Plastid 按课程命名映射为 Chloroplast，但原注释的范围比叶绿体更宽。

训练集 11,085 条，测试集 2,773 条，严格沿用 header 的官方 test 标记。原论文按同源序列簇分组后划分数据 [1]；我们没有重新随机切分，也不根据测试分数挑选模型。完整序列摘要检查发现跨集合完全重复为 0。这项检查能发现重复序列，但不能替代完整的同源性审计。




图 1: 完整数据集的类别与长度分布。少数类别的结果需要更谨慎解释。

### 2.1 四种方法有什么区别？

| 方法               | 更新什么     | 具体设置                          |
|------------------|----------|-------------------------------|
| Frozen + kNN     | 不更新 ESM  | 平均表征 + 余弦距离 5-NN              |
| Linear probing   | 只更新分类头   | 640 维输入, 10 类 softmax         |
| LoRA             | 低秩矩阵和分类头 | query/value, rank 8, alpha 16 |
| Full fine-tuning | 编码器与分类头  | 不使用的 contact head 冻结          |

使用同一个 ESM-2 模型版本。各方法输入最多 512 个残基；较长序列保留首尾、删除中间，以尽量保留定位信号。表征平均时排除 padding 和特殊 token。三种训练方法均按预先设定的 10 轮训练，使用最后 checkpoint；测试集只在训练结束后评估。

LoRA 的做法是保留原权重  $W_0$ ，增加一个小的更新项： $W = W_0 + (\alpha/r)BA$ 。训练时只更新  $A$ 、 $B$  和分类头，因此需要更新的参数少得多 [3]。

### Algorithm 1: LoRA 训练流程

**Input:** 官方训练集、预训练 ESM-2、rank  $r = 8$

冻结原模型权重，初始化低秩矩阵  $A, B$  和分类头；

**for** 每一轮训练 **do**

**for** 每组 *mini-batch* **do**

        保留序列两端并分词，计算 ESM-2 表征；

        对有效残基求平均，通过分类头得到预测；

        累积交叉熵梯度，更新  $A, B$  和分类头；

    保存 checkpoint；

用最后 checkpoint 评估官方测试集；

## 2.2 在什么机器上运行？

正式实验使用 **NVIDIA GeForce RTX 3080 Ti, 12 GiB 显存**。Python 3.11.14, PyTorch 2.6.0+cu124, bitsandbytes 0.45.5。LoRA 和 Full FT 使用 bfloat16、梯度检查点和 8-bit AdamW；Linear 的分类头使用普通 AdamW；Full FT 的实际 batch 为 4，有效 batch 为 16。所有样本、版本和参数均保存在 run.json 中。

若显存不足，代码依次减小 batch、缩短输入、冻结前层；实际是否发生降级以运行记录为准。

本次 Full FT 的实际适配类型为 full，冻结前层数为 0。

## 3 实验流程




图 2: 四条分支使用相同的官方测试集；统一评估与统计。

## 4 实验结果

### 4.1 总体表现

| 方法           | Accuracy | Macro F1 | ECE ↓ | 训练参数        | 时间/min | CUDA 峰值/<br>GiB |
|--------------|----------|----------|-------|-------------|--------|-----------------|
| Frozen + kNN | 0.693    | 0.574    | 0.063 | 0           | 6.9    | 0.77            |
| Linear       | 0.753    | 0.590    | 0.043 | 6,410       | 6.5    | 0.77            |
| LoRA         | 0.771    | 0.614    | 0.145 | 620,810     | 107.4  | 1.07            |
| Full FT      | 0.793    | 0.685    | 0.153 | 148,391,050 | 107.8  | 2.12            |

本次单次运行中，**Full fine-tuning** 的 **Macro F1** 最高，为 **0.685**；固定表征基线为 0.574。Macro F1 对每一类同等计分，因此能补充总体 accuracy 被大类别主导的问题。

时间包含模型准备、训练、推断与保存；Linear 计入共享表征提取成本。显存为 PyTorch 记录的 CUDA 峰值分配量，不等同于 nvidia-smi 的全部设备占用。




图 3: 四种方法需要更新的参数量。kNN 不更新参数，但仍需存储参考样本。




图 4: 性能与参数量、时间的关系；虚线仅连接不被其他点同时超越的方案。

参数少不一定训练快。LoRA 更新参数仅为 Full FT 的 0.42%，峰值显存约为其 50%，但二者均需通过 Transformer 计算梯度，本次总耗时分别为 107.4 和 107.8 分钟，几乎相同。Linear 连同表征提取只需 6.5 分钟，是低预算下很有价值的起点。这里比较的是同一硬件、固定轮数的实测，不代表经过调参后的最优方案。

## 4.2 哪些类别容易，哪些类别困难？




图 5: 每个定位类别的 F1；括号标出测试样本数。




图 6: Frozen 与 Full FT 的预测错误分布：数字是样本数，颜色按行归一化。

类别图能区分“总体提高”和“每类都提高”。少数类别样本更少，分数容易波动；相近位置的混淆只能提示值得进一步检查的现象，不能直接证明某种生物机制。

Full FT 中，Chloroplast 的 F1 为 0.920，而 Lysosome/Vacuole 和 Peroxisome 分别为 0.318、0.449；后两类测试样本只有 64 和 30 条。混淆矩阵还显示，508 条 Cytoplasm 中有 93 条被判为 Nucleus，808 条 Nucleus 中有 77 条被判为 Cytoplasm。这说明更高的总分仍不能消除类别不平衡与相近位置的区分难题。

### 4.3 置信度与稳定性




图 7: 预测置信度与实际正确率的关系；越接近对角线越一致。

ECE 衡量置信度与正确率的差距，越小越好。但低准确率模型也可能有较小 ECE，因此需要一起看分类表现；本实验没有用测试集调校准参数。

本次 Linear 的 ECE 为 0.043，低于 LoRA 的 0.145 和 Full FT 的 0.153。Full FT 虽然分类更准，却更容易给错误预测很高的信心。因此，若需要根据置信度决定是否人工复核，应在独立验证数据上研究校准，不能直接把 softmax 当成可靠概率。Frozen 的 5-NN 投票还可能给真实类别零概率，导致 NLL 很大；评价脚本仅为数值稳定做概率裁剪。




图 8: 不同长度组的准确率，以及遮蔽序列两端后的变化。

长度分组用于检查模型是否只擅长短序列。端点实验把两端各最多 10 个残基替换为 X，用来观察对端点信息的敏感性；这不是实际生物突变，也不能单独证明模型识别了定位信号。

Full FT 对不超过 128 残基的序列准确率为 84.1%，对超过 512 残基的序列为 77.1%。长度组的类别构成也不同，不能把差异全部归因于截断。遮蔽端点后，其准确率从 79.3% 降为 73.2%，与端点信息有帮助的解释一致，但也可能包含输入分布变化的影响。




图 9: 1,000 次配对 bootstrap 得到的 Macro F1 差值区间。

每次重采样对四种方法使用相同测试 ID，并保持观测类别比例。区间跨过零表示这次重采样下差异方向不稳定。区间没有包含训练种子的变化，也不是同源家族独立重采样，不能把它当成所有不确定性的完整范围。

Full FT 相对 LoRA 的 Macro F1 提升为 0.071，配对 95% CI 为 [0.045, 0.097]，区间未跨零。相反，Linear 与 LoRA 的 Macro F1 差异区间跨零，因此这一次实验不足以稳定区分这两种方法的 Macro F1。这里列出的区间是逐项区间，未进行多重比较校正。

#### 4.4 表征与训练过程




图 10: 只在训练表征上拟合 PCA，再展示测试蛋白的投影。




图 11: 训练 loss 和准确率随 epoch 的变化。

PCA 是高维特征的二维投影，只适合观察分布，不应凭图中是否成团来判断模型质量。训练曲线用于确认优化过程；最终泛化表现仍以独立测试集为准。

## 5 讨论与总结

这次实验完成了从下载与清洗、四种适配，到独立测试、统计与作图的完整流程。按本次 Macro F1，Full fine-tuning 表现最好；实际选择还应结合图中的时间、显存与少数类表现，而不是只看一个分数。

需要保留三点限制：第一，只有一个训练种子，不能保证换一次训练仍有同样排名；第二，长序列截断和单标签设定简化了真实定位问题；第三，官方同源划分降低了监督数据泄漏风险，但不能排除 ESM 预训练语料中的重叠。后续最值得补充的是多个随机种子，以及带真实定位信号注释的分析。

**数据与伦理声明：**使用公开研究数据，引用原作者，原始序列不提交到 GitHub。本工作用于课程学习，不用于临床决策。代码与初稿由 AI 辅助，最终实验解释和提交内容由作者审核。

## 6 参考文献

1. Almagro Armenteros JJ, et al. DeepLoc: prediction of protein subcellular localization using deep learning. *Bioinformatics*. 2017;33:3387–3395. doi:10.1093/bioinformatics/btx431.
2. Lin Z, et al. Evolutionary-scale prediction of atomic-level protein structure with a language model. *Science*. 2023;379:1123–1130. doi:10.1126/science.ade2574.
3. Hu EJ, et al. LoRA: Low-Rank Adaptation of Large Language Models. *ICLR*. 2022. arXiv:2106.09685.